

Aparát ověřitelné AI řešerše

Framework, který nechává jazykové modely dělat výzkum — a přitom jim *nevěří*. Každé tvrzení je inventarizováno v grafu; citovaná tvrzení se vážou na registrované zdroje a chybějící evidence dostává explicitní verdikt `NO-SOURCE` místo mlčení. Vzorek tvrzení ověřují mechanicky izolovaní verifikátoři, oponenturu píše model jiného výrobce a proces se zapisuje do hashem řetězeného, externě kotveného záznamu, kde je každý zásah do historie odhalitelný.

3 validační brány 6 verdiktů 850 auditních eventů ověřeno provozem 08/2026

- | | |
|---|--------------------------------------|
| 1. Proč aparát existuje | 6. Verdikty a vzorkování |
| 2. Systém v kontextu (C4) | 7. Akademické standardy |
| 3. Pipeline: preflight + 12 fází, 3 brány | 8. Slepá oponentura |
| 4. Kontejnery a artefakty (C4) | 9. Empirická evidence: běh wearables |
| 5. Důkazní řetěz: hash chain | 10. Profil short (experimentální) |
| | 11. Lekce z provozu |

01 · MOTIVACE

Proč aparát existuje

Jazykový model umí za hodiny sestavit řešerši, na kterou by tým potřeboval týdny. Stejně snadno ale vyrobí přesvědčivě znějící tvrzení, které zdroj nedokládá — nebo zdroj, který neexistuje. Pro rozhodování (a pro akademickou práci) je takový výstup bezcenný, dokud se nedá *doložit, co je ověřené, co ne, a kdo to ověřil*.

Aparát na to odpovídá třemi principy:


Fail-closed. Každá kontrola při pochybnosti selže, nikdy tiše neprojde. Verdikt, který neseďí na schéma, zastaví běh; chybějící artefakt zablokuje bránu.

Mechanická nedůvěra, ne slib. Verifikátor nemá „pokyn nečíst cizí soubory“ — běží v deny-by-default sandboxu operačního systému a pod týmž sandbox profilem se aktivní sondou (canary) měří, že čtení vybrané zakázané cesty skutečně vrátí `denied`. Slib modelu se nepočítá; počítá se změřený výsledek.

Auditní stopa místo důvěry v autora. Autorem výzkumu je model — proto o kvalitě nerozhoduje autor, ale nezávislé instance: verifikační flotila na vzorku tvrzení a oponent z jiné modelové rodiny, oba zapsané do řetězeného záznamu.

02 · C4 — CONTEXT


Systém v kontextu



C4 Context. Orchestrátor deleguje, ale neověřuje — kontrolní role běží v oddělených instancích (čárkovaně = mechanicky izolované). Do control plane se zapisuje právě pět typů důvěryhodných eventů (consent-choice · author-session · runtime-invocation · canary-read · gate-result); verdikty a nálezy tečou do append-only ledgerů, z nichž Gate 3 odvozuje stav — atestace reportu je podmíněná (BLOCKED ji zakazuje).

03 · PROCES

Pipeline: preflight + 12 fází, 3 brány



Fáze a brány. Fáze 0 (preflight se souhlasem a limity) předchází vlastní rešerši ve fázích 1–10. Fáze 11 začíná stavbou úplného grafu tvrzení; teprve nad ním běží brány G1 (sanity_pass) a G2 (validate_report), pak deterministický vzorek a sandboxovaná flotila. Po oponentuře (fáze 12) se G3 větví: stavy CLEAN · RESOLVED · CAPPED · NOT-RUN vedou k zápisu atestace, stav BLOCKED finalizaci zakazuje — běh končí bez atestace.

BRÁNA	SKRIPT	CO VYNUCUJE
Gate 1	sanity_pass.py	strukturální integrita, únik mimo rozsah (kontaminace), pokrytí a distribuce generalizačních tagů
Gate 2	validate_report.py	tier odvozený z počtu citovaných zdrojů vs. deklarovaný, shoda inline citací s registrem a grafem tvrzení
Gate 3	review_gate.py	úplnost verifikace a oponentury, adjudikace nálezů, konzistence hashů — atestaci zapíše jen mimo stav BLOCKED

Kontejnery a artefakty

Autorská rovina

- `claim_sampler.py` — graf tvrzení a deterministický vzorek
- `source_registry.py` — registr zdrojů (schéma r4: appraisal, COI, retrakce)
- `verify_citations.py` — kontrola DOI/URL před zmrazením
- artefakty: `report.md`, `sources.jsonl`, `claims.jsonl`, `claim_evidence_edges.jsonl`

Verifikační rovina

- `verifier_dispatch.py` — sandbox profil + canary + dispatch
- `fleet_runner.py` / `fleet_ledger.py` — sekvenční flotila, crash-resume, append-only stav
- `verify_ledger_builder.py` — ledger pokusů → roll-up → evidence packet
- artefakty: `qa_raw/*` (content-addressed), `claim_verify.jsonl`

Oponentní rovina


- `review_bundle.py` — šestičlenný bundle s připnutým pořadím
- `review_dispatch.py` — sevřený běh oponenta (Codex)
- `blind_ledger_builder.py` — nálezy → adjudikovatelný ledger
- `qa_manifest_builder.py` — hashový manifest pro G3

Důvěrová rovina

- `trusted_control_plane.py` — hash-chained event log
- `record_issuer.py` — continuity verifier (prefix-anchoring)
- `qa_schemas.py` — fail-closed validace všech schémat
- artefakt: `trusted-control-record.json` **mimo run_dir**

Chráněné jádro tvoří **osm globálně zmrazených skriptů** (`claim_sampler`, `validate_report`, `sanity_pass`, `review_gate`, `qa_schemas`, `source_registry`, `verifier_dispatch`, `trusted_control_plane`); návrhové dokumenty v2.2 k nim řadí ještě tři chráněné závislosti (`source_evaluator`, `verifier_envelope`, `review_bundle`). Změna kontraktu kteréhokoli z nich by zneplatnila rozběhnuté výzkumy, proto se nové schopnosti přidávají výhradně novými skripty vedle nich.

Důkazní řetěz



Tamper-evident, externě kotvený důkaz. Změna kteréhokoli staršího eventu rozbije otisky všech následujících. Kotva žije mimo adresář výzkumu; průběžné znovuvydání provádí `record_issuer.py` s kontrolou, že starý řetěz je doslovným prefixem nového. Kotvu zapisují i další důvěryhodné orchestrátorské nástroje (`gate_result_recorder.py` po zápisu bran, `control_plane_reset.py` při záměrném, zálohovaném resetu) — model tedy nestojí na fyzické nesmazatelnosti, ale na tom, že každý zásah do historie je buď prefixové prodloužení, nebo auditovatelná operace důvěryhodného zapisovatele mimo dosah běhu; cokoli jiného kotva odhalí.

06 · MĚŘENÍ

Verdikty a vzorkování

Verifikátor dostane tvrzení, vazbu na zdroj a plný text zdroje — a vrátí právě jeden z šesti verdiktů. U `SUPPORTED` ověřuje `verify_shim.py`, že citát je doslovně obsažen ve zdrojovém textu; `qa_schemas.py` pak fail-closed vynucuje neprázdný citát, lokátor, typ podpory a hashe zdroje i obsahu.

■ SUPPORTED ■ PARTIAL ■ UNSUPPORTED ■ CONTRADICTED ■ SOURCE-UNAVAILABLE
■ NO-SOURCE


Vzorek nevzniká náhodně. **Úplným ověřením** (census, tj. bez vzorkování) prochází každé formální zjištění (`finding`) a všechny jednotky s příznaky `executive_summary`, `high_confidence`, `numeric`, `safety`, `legal`, `decision_critical` a `recommendation_support`; profil pro vysoké sázky navíc saturuje `high_stakes_assertion`. Teprve *zbývající* běžná tvrzení se vzorkují deterministickým 20% výběrem s kvótami po sekcích. „Náhoda“ výběru je třídící klíč `sha256(report_core_sha256 + ":" + claim_hash)` — výběr je reprodukovatelný a vázaný na přesnou verzi reportu, bez generátoru náhody. Souhrn páru se skládá konzervativně: nejhorší verdikt vyhrává (`CONTRADICTED` → `UNSUPPORTED` → `NO-SOURCE` → `PARTIAL` → `SOURCE-UNAVAILABLE` → `SUPPORTED`).

Akademické standardy uvnitř aparátu

Aparát nedeklaruje formální systematickou rešerši — přejímá z těchto standardů účetní a hodnotící disciplínu a používá je jako závazné čochky, ne jako odškrtnuté checklisty.

STANDARD	KDE V APARÁTU ŽIJE
PRISMA 2020 / PRISMA-S (v duchu)	logované dotazy pro každý nástroj, důvod u každého vyloučeného zdroje, flow tabulka generovaná <code>source_registry.py prisma</code> ; výstup se nevydává za systematic review
GRADE (zjednodušený)	High/Medium/Low s downgrade doménami (risk of bias, inconsistency, indirectness, imprecision, publication bias) na úrovni tvrzení
Triangulace	tier-floor počtu <i>nezávislých</i> zdrojů na tvrzení; nezávislost podle linie vydavatele, autorů a financování (<code>independence_group</code> v grafu hran) — oponentura ji explicitně prověřuje
COI / financování	pole <code>funding_coi</code> v registru + vendor-funded dependency check v kritické fázi; AACODS u šedé literatury
Generalizabilita	povinné tagy     na každém zjištění; brána kontroluje distribuci, oponent šířku tagu proti síle evidence
Oborové čochky	Kitchenham SLR (IT), Tranfield (management), CONSORT-AI / TRIPOD+AI / STARD-AI a další pro AI-in-health — jako appraisal lens, ne certifikace

Slepá oponentura



Slepota jako mechanika s přiznanými hranicemi. Oponent nedostává autorskou konverzaci a bundle je jediná zpřístupněná evidence výzkumného běhu; sandbox mu vedle něj ponechává čitelné jen systémové a runtime allowlisty a zápis jen do pracovního adresáře. Canary je aktivní sonda vybrané zakázané cesty, spuštěná pod tímž sandbox profilem v bezprostředně předcházejícím volání — dokazuje vynucení profilu, ne univerzální slepotu. Zákaz webu a fact-checkingu ukládá rubrika (pravidlo role, ne mechanika). Adjudikace nálezů má rozpočet (1 plné kolo + 2 potvrzovací) a každé přijetí vynucuje opravu, přeoveryení a nový bundle proti novému hashi.

09 · EVIDENCE

Empirická evidence: běh wearables

Aparát není návrh — v srpnu 2026 dokončil **produkční datovou sadu a kontrolní cvičení v plném měřítku** nad rešerší klinické validity nositelných zařízení. Výsledný manifest zůstal poctivě ve stavu BLOCKED (viz níže); všechna čísla jsou z vlastních auditních artefaktů běhu.

316

ověřovaných párů
tvrzení ↔ zdroj (úplné
třídy + 20% vzorek)

421

sandboxovaných
verifikačních běhů v
control plane

43 %

pokrytí ověřením
(floor 138/316;
konzervativně dolů)

14

nálezů cross-family
oponenta (6 Critical, 8
Major)

850

hash-řetězených
eventů v trusted
control plane



Jediný CONTRADICTED (0,32 %) je v pruhu vykreslen s minimální viditelnou šířkou, aby nezanikl.

Brány: **Gate 1 PASS** **Gate 2 PASS** **Gate 3 BLOCKED** — a právě ta poslední je nejcennější doklad. Finalizace odmítla vydat atestaci a vypsala **1 085 validačních chyb napříč doloženými třídami**: 913 nekanonických JSON záznamů ve vstupních artefaktech, 156 nevyřešených párů, spálený rozpočet oponentury (první kolo zabila Gatekeeper karanténa na hostiteli), neúplný oponentní ledger pro zablokované kolo, chybějící flag-audit nástroj, tři tvrzení pod triangulační podlahou a dvě nesrovnalosti projekce/rederivace. Aparát tedy *odmítl orazítkovat vlastní běh*, místo aby vady zamlčel — u frameworku, jehož smyslem je nedůvěra, je to funkce, ne selhání.

Cross-family doloženo v datech: autor `claude-sonnet-5` (rodina `claude`), oponent `gpt-5.6-sol` (rodina `openai`), `read_confinement: os-sandbox-allowlist` — vše zapsané v manifestu a control plane, ne v prohlášení autora.

10 · ODLEHČENÝ REŽIM

Profil short (experimentální)

Profil short je **experimentální rozšíření mimo aktivní SKILL.md** (ten zná jediný režim, MAXIMUM): specifikace v2 vznikla 27. 8. 2026 po slepé oponentuře (verze 1 dostala 4 Critical a 4 Major nálezy) a byl nasazen na doplňkové běhy pro tuto práci.

Zachovává

- protokol předem (scope, kritéria, dotazy)
- plný registr zdrojů vč. appraisalu a COI
- graf tvrzení + deterministický vzorek (beze změny)
- brány G1 a G2 byte-přesně
- append-only spot-check ledger vázaný na hash reportu

Vypouští — a přiznává

- sandboxovanou verifikační flotilu — **spot-check verifikátor běží bez OS sandboxu**
- slepou oponenturu
- hash-chained control plane a G3 atestaci
- místo nich: deklarace NOT-RUN — short profile přímo v reportu, zapsaná fail-closed finalizerem

Decision-critical tvrzení (taková, jejichž vyvrácení by změnilo go/no-go, finanční práh nebo právní přípustnost) dostávají i v short profilu **úplné ověření všech svých párů**, ne vzorek. Nepříznivý verdikt se nikdy neřeší prózou — jen zúžením či odstraněním tvrzení, výměnou nebo odstraněním evidence, či snížením confidence; každá taková

editace vynucuje nové ověření proti novému hashi reportu a odstranění se ve finalizeru vykazuje odděleně (resolved-by-removal).

11 · PROVOZ

Lekce z provozu

Falešný úspěch je horší než pád. Smoke sonda místo verifieru vracela verdikt natvrdo — odhalilo ji až schéma, které odmítlo „žádný zdroj“ u páru, který zdroj měl. Od té doby platí: každý mezivýsledek validovat schématem, návratovému kódu nevěřit (headless běh umí skončit nulou s neudělanou prací).

Prostředí je součástí důkazu. Gatekeeper karanténa binárek dokázala zablokovat oponenturu tak, že vypadala jako timeout runtime; izolace se proto prokazuje sondou na témže stroji a buildu, kde běží ostrý běh.

Verifikátoři oscilují. Hraniční tvrzení dostávají od nezávislých běhů různé verdikty; konvergenci zajišťuje append-only ledger (historie se nikdy nepřepisuje) a pravidlo, že poslední kolo před finalizací needituje.

Pojistky platí i na autora aparátu. Nákladová brána z fáze 0 zablokovala vlastní finalizaci běhu, dokud se re-odhad nespočítal metodicky správně; nedefinovaná jednotka odhadu je zdokumentovaná vada pro další verzi.

Autor a design authority: Martin Ždimera

deep-research-martins · v2.1.2 + v2.2 vlna 1 · stav k 2026-08-28 · podklad přílohy A diplomové práce

dokument sestavil orchestrátor session 2026-08-28 nad inventářem repozitáře (SKILL.md, methodology.md, auditní docs/)

verze 3 – slepá oponentura Codex nad v1 (4 Critical, 7 Major, 3 Minor; protokol: docs/reviews/2026-08-28-framework-prezentace-oponentura-codex.md), potvrzovací kolo

nad v2 (9 resolved, 5 partially → dořešeno zde); v1 zachycena ve verzní historii artefaktu, v2 = git e6bf8a9, remediace ověřitelná diffem